

SIAN recolección histórica y análisis de narrativas

Resumen

Este documento describe el algoritmo implementado, desde la aplicación local, para construir y analizar un corpus narrativo trazable. La propuesta separa rubros de variantes, años y capas de fuente; guarda bases parciales; fusiona registros en un archivo estructurado; limpia los textos antes de interpretarlos; produce indicios cuantitativos, mapas de relaciones narrativas, disección estructural de proposiciones y selecciones revisables de actores, ideas o fuentes que merecen lectura cercana. El diseño evita mezclar noticias, foros y artículos científicos como si fueran una única voz homogénea. La tesis metodológica es pasar de *Big Data* a *Smart Data*: no importa acumular textos indiscriminadamente, sino construir evidencia pública, estratificada, trazable y conceptualmente pertinente. El resultado no es una interpretación automática, sino una infraestructura de lectura: un corpus organizado, auditable y preparado para contrastar hipótesis narrativas.

1 Principio metodológico

El sistema se diseña para tópicos cambiantes. El tópico puede ser *tatuaje*, *programación con IA*, *violencia*, u otro. El punto crítico es no buscar una cadena larga con conectores como si fuera una consulta única. En lugar de ello, se separan rubros conceptuales:

$$R = \{r_1, r_2, \dots, r_p\},$$

años:

$$Y = \{y_0, y_0 + 1, \dots, y_f\},$$

y capas de fuente:

$$S = \{\text{noticias, foros, artículos, reportes}\}.$$

El marco de lectura distingue estas dimensiones, sin exigir el producto completo de consultas:

$$\forall r \in R, \quad \forall y \in Y, \quad \forall s \in S.$$

Así se sabe qué parte terminó, qué parte falló y qué capa quedó vacía. Esto es preferible a una búsqueda mezclada que produce una base grande pero sesgada.

Este procedimiento no busca medir directamente una realidad social, sino construir un corpus trazable de huellas discursivas. Su utilidad está en permitir comparar cómo distintos géneros de fuente —prensa, foros, documentos institucionales y literatura académica— estabilizan, transforman o disputan una narrativa a lo largo del tiempo.

La unidad de análisis no es sólo la palabra clave. El sistema identifica fuentes, marcos argumentales, cambios temporales, silencios relevantes, proposiciones y relaciones entre actores, ideas, documentos y capas de fuente. Por ello, los resultados deben leerse como señales estructurales para guiar una lectura crítica, no como veredictos de verdad ni como prueba judicial cerrada.

2 Fases del procedimiento

Para facilitar la lectura desde humanidades, el algoritmo puede entenderse como nueve fases. Cada fase responde una pregunta metodológica distinta. La parte computacional no sustituye la interpretación; organiza materiales, deja rastro de las decisiones y permite comparar capas discursivas.

Fase	Qué se hace	Por qué se hace
1. Delimitar	Se define el tópico, la región, los años y los rubros de búsqueda.	Evita que el corpus sea una mezcla accidental de sentidos distintos del mismo término.
2. Reunir voces	Se buscan documentos por año y por capa: noticias, foros, artículos y reportes.	Permite distinguir diálogo social, prensa, producción académica y documentos institucionales.
3. Depurar	Se limpian textos, se eliminan duplicados, menús, publicidad, palabras vacías y exclusiones conceptuales.	Reduce ruido antes de construir patrones; no se interpreta texto contaminado como si fuera discurso social.
4. Describir	Se calculan frecuencias, frases repetidas, tonalidad léxica exploratoria y eventos narrativos.	Produce una primera lectura cuantitativa y auditable del corpus.
5. Podar inteligentemente	Se identifican fuentes con mayor peso estructural, marcos repetidos y documentos que sólo actúan como eco.	Evita confundir volumen documental con diversidad narrativa.
6. Diseccionar	Se extraen proposiciones, actos de habla, relaciones causales, marcadores retóricos revisables y ausencias relativas dentro del corpus.	Permite pasar de contar palabras a observar estructura argumental.
7. Relacionar	Se construyen redes de documentos, actores, fuentes, años, conceptos, proposiciones y etapas narrativas.	Permite observar cómo se conectan voces, temas y momentos del relato.
8. Seleccionar	Se resuelve el problema del cubridor nodal sobre la red ponderada y se comparan métodos bajo el mismo supuesto.	Resume la red en un conjunto revisable de nodos que cubren relaciones relevantes.
9. Sintetizar	Se exportan corpus, tablas, grafos, trazabilidad técnica y resultados de métodos.	Facilita comparar soluciones, revisar evidencia y preparar análisis interpretativo o publicación.

Cuadro 1: Fases del sistema explicadas para lectores no especializados en computación.

Las fases no constituyen una cadena mecánica de descubrimiento. Cada una reduce una forma distinta de ambigüedad: la delimitación reduce ambigüedad conceptual; la recolección reduce ambigüedad de procedencia; la depuración reduce ruido documental; la descripción produce indicios; la poda evita acumulación redundante; la disección separa proposiciones y actos de habla; la red muestra relaciones posibles; el cubridor resume estructura; y la síntesis prepara preguntas interpretativas que deben volver al corpus.




Figura 1: Resumen de fases para lectura humanística: el proceso es iterativo y auditable.

3 Arquitectura general

La Figura 2 debe leerse de izquierda a derecha y de arriba abajo. La primera línea corresponde a decisiones de investigación: qué se estudia, con qué variantes y en qué marco temporal o geográfico. La segunda línea corresponde a la recolección: reunir voces sin confundirlas. La tercera línea corresponde al cuidado del corpus: limpiar, registrar y fusionar sin perder trazabilidad. La última línea corresponde al análisis: describir patrones, observar relaciones y producir una síntesis revisable.

4 Coordinador histórico y tareas recuperables

La versión de ejecución 3 guarda primero el plan y después ejecuta tareas por periodo, consulta y capacidad de fuente. Los motores académicos usan periodos anuales; las fuentes públicas usan ventanas mensuales. Los años y capas se intercalan. Los rubros clasifican el texto recuperado y no multiplican la meta. La cuota total anual comparte documentos entre todas las capas.

Documento, versión y recuperación son unidades distintas. DOI y URL canónica definen identidad. No se fusionan documentos distintos por títulos similares. Las copias exactas entre URLs se conservan con relación de duplicado, pero sólo una cuenta para la cuota. Publicación explícita y válida determina el año; detección, consulta, actualización y `lastmod` no lo sustituyen.

El proceso confirma cada documento antes de cerrar una tarea. Un bloqueo impide dos trabajadores por base. Recargar la página no cancela el trabajador. La pérdida del disco requiere un volumen persistente, respaldo externo configurado o un ZIP completo conservado por la persona. Los ZIP anteriores pueden migrarse sin inventar documentos recuperados. La interfaz distingue cuota alcanzada, pausa, interrupción, fuentes pendientes y final con brechas. El año corriente se corta al presente. El manual completo está en `RECOLECCION_HISTORICA.md`.

Esta fase existe para evitar una ilusión frecuente: obtener muchos documentos pero de una sola clase. Si sólo aparecen artículos científicos, no hay base suficiente para hablar de conversación social; si sólo aparecen noticias, falta contrastar con foros o producción académica. La corrida secuencial muestra los vacíos en lugar de ocultarlos.




Figura 2: Arquitectura general expresada como flujo de decisiones interpretativas y cómputo local.

5 Extracción responsable y estados de evidencia

La recolección distingue entre encontrar una referencia, descargar texto completo y conservar sólo una señal parcial. Esta distinción es ética y metodológica: evita tratar un resumen RSS, un título indexado o una página con restricción como si fuera texto completo.

En consecuencia, los estados no son detalles técnicos sino categorías de evidencia. `ok` indica texto recuperado utilizable, sin certificar extensión completa; `ok_partial` indica una señal pública útil pero limitada; `too_short` preserva registros breves que no deben inflar análisis de texto; y los errores se reportan como límites de la muestra. La publicación debe informar cuántos registros pertenecen a cada estado.

6 Limpieza, composición de frases y análisis local

Para cada documento d , el texto se normaliza antes de construir conceptos:

$$\text{text}(d) \rightarrow \text{lowercase} \rightarrow \text{normalización} \rightarrow \text{stopwords} \rightarrow \text{tokens}.$$

Luego se extraen monogramas, bigramas y trigramas. Si una frase repetida explica la mayor parte de las apariciones de sus componentes, se usa como nodo canónico:

$$q \prec p \quad \text{si} \quad q \subset p, \quad \frac{\text{freq}(p)}{\text{freq}(q)} \geq \theta, \quad \text{freq}(p) \geq 2.$$

La limpieza no es un trámite técnico menor. En páginas web, el texto puede traer menús, publicidad, biografías de autores, notas relacionadas o palabras vacías. Si ese ruido entra al análisis, la red puede destacar términos irrelevantes. Por eso se depura antes de contar palabras, detectar




Figura 3: Ejecución independiente de la página. Los límites del proveedor quedan guardados y las tareas pendientes pueden reanudarse.

frases o construir relaciones. La composición de frases busca respetar unidades de sentido: una expresión repetida como *arte corporal* o *tatuaje religioso* puede ser más informativa que sus palabras separadas.

7 Tonalidad léxica local y radar por fuente

La tonalidad léxica se calcula con un léxico local bilingüe. Para cada documento se parte de:

$$tono(d) = \frac{pos(d) - neg(d)}{pos(d) + neg(d)},$$

con $tono(d) = 0$ si no hay términos positivos ni negativos. En la aplicación se incorporan reglas simples de negación e intensificación: expresiones como “no seguro” invierten la orientación inmediata, mientras que intensificadores como “muy” aumentan el peso local de una palabra valorativa. Para graficar en radar se usa:

$$rad(d) = \frac{tono(d) + 1}{2} \in [0, 1].$$

El promedio por año y fuente es:

$$\bar{s}_{y,c} = \frac{1}{|D_{y,c}|} \sum_{d \in D_{y,c}} tono(d).$$




Figura 4: Extracción responsable: el sistema no fuerza sitios cerrados; conserva metadatos parciales cuando no hay permiso de texto completo.




Figura 5: Preparación del texto antes de construir mapas de relaciones.

Cada eje del radar representa un tipo de fuente. Esta medición es exploratoria: sirve para comparar capas discursivas, no para inferir emociones individuales.

En términos interpretativos, el radar no dice “lo que siente la sociedad” ni describe estados psicológicos de autores individuales. Dice si, dentro del corpus recolectado, una capa discursiva usa con mayor frecuencia vocabulario valorativo positivo, negativo o mixto. Por eso debe leerse junto con ejemplos textuales y con la distribución de fuentes por año.

8 Redes construidas

La red se usa como mapa de relaciones, no como sustituto de lectura crítica. Permite observar qué actores aparecen cerca de qué ideas, qué momentos del relato se repiten, qué fuentes concentran ciertos temas y cómo cambian esos patrones por año o localización.

Los pesos se asignan por conteo:

$$w_a = \sum_{d \in D} \mathbf{1}\{a \text{ aparece en } d\}.$$

Se conserva el peso crudo y se normaliza:

$$\tilde{w}_a = \frac{w_a}{\max_{b \in A} w_b}.$$

La red semántica usa coocurrencias entre conceptos. El grafo de conocimiento agrega conceptos, fuentes, años, idioma, localización y tipo de fuente. Cuando Louvain está disponible, se calculan comunidades; si no, se reporta la alternativa local usada.




Figura 6: Red narrativa: cada texto conecta actores, ideas, momentos del relato, fuentes, años y lugares.

9 Cubridor nodal multiobjetivo

Esta sección formaliza una pregunta interpretativa simple: si el mapa narrativo contiene demasiados elementos para revisarlos uno por uno, ¿qué conjunto pequeño de actores, ideas, fuentes o momentos del relato permite iniciar una lectura crítica sin borrar la complejidad de la red? En adelante llamamos nodos relevantes a los elementos que concentran relaciones dentro del corpus. La formalización matemática permite comparar distintas selecciones, pero la relevancia final depende de lectura crítica y contraste con ejemplos textuales.

Sea $G = (V, A)$ una red ponderada. El universo del problema es el conjunto de aristas objetivo:

$$\mathcal{U} = A^* \subseteq A.$$

Cada nodo candidato $v \in B \subseteq V$ cubre sus aristas incidentes:

$$S_v = \{a \in A^* : a \sim v\}.$$

La solución es un conjunto $C \subseteq B$. Con variables binarias x_v y r_a :

$$x_v = 1 \Leftrightarrow v \in C, \quad r_a = 1 \Leftrightarrow a \text{ toca algún nodo seleccionado.}$$

La condición de arista removida se modela con:

$$\begin{aligned} r_a &\geq b_{av}x_v, \quad \forall a \in A^*, \forall v \in B, \\ r_a &\leq \sum_{v \in B} b_{av}x_v, \quad \forall a \in A^*. \end{aligned}$$

Esto evita confundir el daño estructural con el subgrafo inducido. Una arista se cuenta como perdida si al retirar el conjunto seleccionado toca al menos un nodo del cubridor.

Los objetivos normalizados son:

$$f_1(C) = \frac{\sum_v x_v}{|B|} \quad \text{minimizar,}$$




Figura 7: Síntesis revisable: del corpus al mapa, del mapa a nodos relevantes y de allí a lectura crítica.

La última fase selecciona un conjunto pequeño de nodos que ayude a explicar el mapa sin destruirlo. Esta selección no pretende reemplazar el análisis interpretativo. Funciona como una herramienta para preguntar: ¿qué actores, ideas o fuentes son centrales?, ¿qué relaciones se perderían si quitáramos esos nodos?, ¿hay varias síntesis igualmente defendibles?

La aplicación puede comparar varias estrategias de búsqueda de soluciones: barrido glotón por prioridades, búsqueda evolutiva multiobjetivo, recocido multiobjetivo y una adaptación multiobjetivo del método de composición musical. Para no cargar la figura con siglas, la Figura 7 muestra la pregunta común que comparten esos métodos.

La factibilidad se compara con criterio de Coello:

$$\text{factible} \succ \text{infactible}.$$

Entre dos infactibles gana la menor violación total. Entre dos factibles se aplica dominancia de Pareto. Todos los métodos deben usar el mismo presupuesto de evaluaciones de la función objetivo.

El MMC-MO resuelve una sola vez las relajaciones monoobjetivo de referencia y las guarda como memoria inicial. Después modifica esa guía con soluciones no dominadas encontradas durante la búsqueda; no debe resolver los problemas relajados en cada iteración.

10 Exportación final

La salida de análisis se integra en:

`narrative_analysis_unified.json`.

Este archivo contiene registros filtrados, tonalidad léxica, eventos narrativos, actores, grupos de ideas, red narrativa, red semántica, grafo de conocimiento, cubridor y frente Pareto. Es la unidad reproducible para publicación y análisis posterior.

11 Actualización: evidencia disponible y requisitos de análisis (6 de octubre de 2026)

Esta actualización prevalece sobre supuestos anteriores de disponibilidad completa. Autoría, fecha y fuente se buscan, pero su recuperación no está garantizada. Cada campo conserva valor, evi-

dencia, método y estado: explícito, inferido, buscado y no encontrado, no evaluable, no aplica o contradictorio. Se conservan candidatos contradictorios sin elegir arbitrariamente.

Publicación, actualización y consulta son fechas distintas. La precisión puede ser año, mes o día; no se completa información ausente. El año de búsqueda se conserva como `search_year`; `year` sólo refleja publicación explícita utilizable. Una fecha de detección de índice no es publicación. Un enlace PDF no acredita recuperación de texto completo.

Un documento sin autor o fecha puede aportar al análisis temático. Cada análisis presenta documentos utilizables, total, motivos de exclusión y cobertura por tipo de fuente. La cobertura no garantiza representatividad o suficiencia estadística. Los registros antiguos de fecha ambigua necesitan revisión humana para entrar en comparaciones temporales. El dominio de una URL no equivale a firma personal, editor identificado o ubicación del acontecimiento.

11.1 Representaciones matemáticas y revisión

La matriz documento–concepto usa 1 para presencia revisada, 0 sólo para ausencia tras revisión explícita del concepto y valor faltante para lo no evaluado. La proporción fuente–concepto usa como denominador los documentos efectivamente revisados para ese concepto. La red actor–concepto–postura conserva apoyo, rechazo y ambivalencia por separado; requiere cita literal y atribución revisada. Las relaciones dirigidas conservan tipo, documento y fragmento. Una causalidad atribuida por el texto no constituye un efecto causal demostrado. Los conteos temporales se calculan sobre la intersección revisada y fechada, con cobertura explícita. No equivalen a cambio en la opinión poblacional.

Los módulos heurísticos anteriores generan candidatos exploratorios. El módulo `evidence_model.py` verifica estados y citas, pero no sustituye juicio disciplinar. Las revisiones entran mediante JSON y se conservan al exportar el corpus. No se infiere recepción a partir del mensaje original. Las observaciones pueden depender de una misma institución o acontecimiento; no se implementan pruebas inferenciales ni difusión con estos conteos.

11.2 Pseudocódigo de operación

1. Recuperar contenido y procedencia; buscar metadatos etiquetados cuando sea posible.
2. Conservar valor, evidencia y estado de cada campo; preservar conflictos y precisión.
3. Separar publicación, actualización, consulta y año de búsqueda.
4. Comprobar requisitos por análisis; registrar inclusión o motivo de exclusión.
5. Validar citas literales y atribuciones en las revisiones recibidas.
6. Construir matrices con valores faltantes distintos de cero; conservar signos de postura.
7. Exportar cobertura, matrices, relaciones y limitaciones del subconjunto utilizado.

La política completa, ejemplos y comandos reproducibles están en `EVIDENCIA_Y_MODELOS.md`. Los informes históricos no se convierten en nuevas mediciones por actualizar el software.

11.3 Contrato integral de corpus

La identidad y fusión se centralizan en `corpus_contract.py`, compartido por la interfaz y los comandos. Se conservan parámetros identificadores de URL, procedencias, variantes textuales y conflictos. La similitud de títulos no basta para fusionar trabajos distintos. Las señales de silencio indican no detección en fragmentos recuperados; no acreditan que una fuente ignore un tema. Las fechas anuales no permiten ordenar publicaciones dentro del año. El exportador relacional conserva tablas vacías cuando no existen interpretaciones revisadas. Véase `AUDITORIA_INTEGRAL_2026-10-06.md` para pruebas y límites del piloto.

11.4 Registros y etapas v2

Documento, versión y recuperación tienen identificadores separados. La selección requiere motivo, evidencia y revisor; los cambios invalidan interpretaciones previas. Se distinguen títulos, resúmenes y fragmentos. Descubrimiento, recuperación, extracción, selección, revisión y análisis tienen puntos de control para reanudación. El ejecutor de corpus guardados organiza la evidencia existente, sin simular nuevas descargas. Caché, reintentos limitados y registro transaccional complementan la escritura atómica. La especificación y pseudocódigo están en `ARQUITECTURA_REGISTROS_V2.md`.