

Modelo local de red narrativa ponderada y cubridor nodal

1. Objeto y alcance

Se propone un sistema local para analizar narrativas en corpus documentales. El sistema no envía textos a modelos externos. Extrae documentos, limpia y normaliza texto, clasifica fuentes, identifica estructura narrativa y construye una red compleja ponderada para resolver un cubridor nodal narrativo. El objetivo no es inferir “la narrativa total” de un tema, sino producir una muestra auditable, filtrable y reproducible de relaciones narrativas.

El modelo adopta una lógica de *Smart Data*: antes de optimizar, separa capas de fuente, elimina ruido, identifica marcos argumentales, detecta ecos documentales, registra cambios temporales y conserva trazabilidad técnica. Por lo tanto, el cubridor no se aplica sobre texto crudo, sino sobre una red ya normalizada, estratificada y revisable.

La tubería separa explícitamente cuatro géneros de fuente: artículos científicos abiertos, noticias, foros/discusiones públicas y fuentes institucionales o industriales. Esta separación evita mezclar evidencia de distinta naturaleza como si tuviera el mismo peso.

2. Preprocesamiento y extracción narrativa

Antes del análisis lingüístico, los textos se homogeneizan en minúsculas, se normalizan acentos, se eliminan URL, puntuación no informativa y palabras vacías en español e inglés. La extracción de monogramas, bigramas, trigramas y redes de coocurrencia se realiza sobre este texto normalizado. Para detectar personas u organizaciones se conserva también el texto editorial original, pero se filtran etiquetas metodológicas y ruido como *abstract*, *conclusion*, *journal*, nombres de fuente y términos que son el propio tópico de búsqueda.

Para cada documento d_i se extraen cinco etapas narrativas:

$$E = \{\text{evento inicial, conflicto, punto de cambio, resolución, consecuencias}\}.$$

También se extraen actores, fuente, año, localización y tipo de fuente. La extracción es heurística y auditable: cada etapa conserva la oración detectada y los marcadores textuales que activaron la clasificación. Los actores se tratan como candidatos, no como verdad automática.

Además, se extraen proposiciones simples de la forma sujeto–verbo–objeto, actos de habla aproximados, marcadores de causalidad y señales argumentales. Las salidas no se interpretan como prueba de verdad, sino como una lista de lugares del corpus que requieren lectura humana.

3. Núcleo Smart Data y ontología de relaciones

Antes de construir el cubridor, el sistema organiza la información en cuatro capas: cartografía de fuentes, marcos argumentales, evolución temporal y silencios. Para cada documento se estiman marcos del tipo:

$$M_d = (\text{problema}_d, \text{culpable}_d, \text{solucion}_d, \text{urgencia}_d),$$

cuando el texto contiene señales suficientes. Si varios documentos repiten el mismo marco, se registra como eco y no como diversidad narrativa adicional.

La red distingue relaciones como:

$$\mathcal{R} = \{\text{afirma, apoya, critica, causa, amplifica, contradice, silencia, contextualiza}\}.$$

Estas etiquetas son operativas y revisables. No prueban intencionalidad; sirven para ordenar el análisis y hacer visible qué tipo de conexión sostiene cada arista.

4. Validación humana de actores

Los actores automáticos no se consideran definitivos. El sistema incorpora una intervención humana para aceptar, corregir, rechazar o agregar actores por documento. La validación se guarda localmente en `actor_validation.json` con estado, validador, notas y fecha. Cuando existe validación, la red narrativa usa los actores validados; si el registro es rechazado, el documento no aporta actores a la red.

5. Red narrativa

La red narrativa se define como:

$$G = (V, A, w, \tau, \sigma),$$

donde V es el conjunto de nodos, A el conjunto de aristas ponderadas, $w : A \rightarrow \mathbb{R}^+$ asigna peso a cada relación, $\tau : V \rightarrow \mathcal{T}$ indica el tipo de nodo y $\sigma : V \rightarrow \mathbb{R}^+$ asigna importancia estructural-narrativa al nodo.

Los nodos incluyen:

$$V = V_D \cup V_R \cup V_Q \cup V_F \cup V_T \cup V_L \cup V_C \cup V_N,$$

donde V_D son documentos, V_R actores, V_Q etapas narrativas, V_F fuentes, V_T años, V_L localizaciones, V_C tipos de fuente y V_N conceptos lingüísticos: monogramas, bigramas y trigramas.

Además se define una capa de flujo narrativo:

$$F = \{\text{diálogo individual, noticia, derivación técnica, investigación, otras derivaciones}\}.$$

Esta capa no impone peso automático. Sirve para observar circulación: el diálogo individual puede preceder a la noticia, la noticia puede preceder a la investigación, y los resultados de investigación pueden retroalimentar diálogos y noticias posteriores.

Las aristas representan relaciones como:

- documento–actor, documento–etapa y documento–concepto;
- actor–etapa, fuente–etapa, año–etapa y localización–etapa;
- fuente–concepto y coocurrencia concepto–concepto.

Cada arista $a \in A$ se representa como una terna:

$$a = (i, j, \rho), \quad i, j \in V, \quad \rho \in \mathcal{R},$$

donde ρ es el tipo de relación. Para evitar introducir una jerarquía artificial entre elementos de narrativa social, el modo base usa ponderación neutral:

$$w_a = \sum_{d \in D} \mathbf{1}\{a \text{ aparece en } d\}.$$

Así, una relación pesa más sólo porque aparece más veces en el corpus filtrado, no porque el investigador haya decidido de antemano que una etapa, fuente o actor vale más que otro. Los tipos de fuente se usan para estratificar y comparar resultados. Si se usa un peso de evidencia ω_d , debe declararse como análisis de sensibilidad:

$$w_a^{sens} = \sum_{d \in D} \mathbf{1}\{a \text{ aparece en } d\} \cdot \omega_d.$$

Esta distinción es importante porque distintos pesos producen sesgos distintos en la red y, por tanto, en el cubridor.

Para comparación estructural se conserva el conteo crudo y se añade una versión normalizada:

$$\tilde{w}_a = \frac{w_a}{\max_{b \in A} w_b} \in [0, 1], \quad \tilde{c}_v = \frac{c_v}{\max_{u \in V} c_u} \in [0, 1],$$

donde c_v es el conteo de apariciones del nodo. El grado ponderado también se normaliza:

$$\tilde{d}_v^w = \frac{\sum_{a \sim v} w_a}{\max_{u \in V} \sum_{b \sim u} w_b}.$$

Así, los pesos usados para comparar redes oscilan entre 0 y 1, mientras que los conteos crudos quedan disponibles para auditoría.

Antes de crear los grafos semántico y de conocimiento se realiza composición de frases. Si un monograma o bigrama está explicado mayoritariamente por una frase repetida más larga, se marca como absorbido:

$$q \prec p \quad \text{si} \quad q \subset p \text{ y } \frac{\text{freq}(p)}{\text{freq}(q)} \geq \theta.$$

Por ejemplo, si *violencia social* explica la mayoría de apariciones de *violencia* y *social*, el nodo principal es la frase completa y las aristas de coocurrencia y documento–concepto se construyen con esa unidad canónica. Para evitar conceptos accidentales, la frase canónica debe repetirse al menos dos veces en el corpus filtrado.

La importancia nodal usada por el cubridor combina frecuencia y estructura, sin ponderar por tipo narrativo en el escenario base:

$$\sigma_v = \gamma_1 \tilde{c}_v + \gamma_2 \tilde{d}_v^w + \gamma_3 \hat{e}v_v + \gamma_4 \widehat{val}_v,$$

donde $\widehat{\text{freq}}_v$ es frecuencia normalizada, $\widehat{\text{deg}}_v^w$ es grado ponderado normalizado, $\hat{e}v_v$ es evidencia promedio asociada al nodo y $\widehat{val}_v$ registra validación humana. En el análisis base se recomienda fijar $\gamma_3 = 0$ si se mezclan géneros de fuente, y usar $\hat{e}v_v$ sólo en corridas de sensibilidad o en análisis separado por tipo de fuente. Los parámetros $\gamma_i \geq 0$ satisfacen $\sum_i \gamma_i = 1$.

6. Problema multiobjetivo de cobertura de conjuntos

El problema se formula como una adaptación explícita del *set covering problem* (SCP). Sea el universo de relaciones que se desea explicar:

$$\mathcal{U} = A^* \subseteq A,$$

donde A^* se obtiene aplicando filtros metodológicos: tipos de arista permitidos, peso mínimo, fuentes incluidas y exclusiones manuales. Cada nodo candidato $v \in B \subseteq V$ define un subconjunto:

$$S_v = \{a \in A^* : a \text{ es incidente a } v\}.$$

La familia de subconjuntos es:

$$\mathcal{S} = \{S_v : v \in B\}.$$

Una cobertura clásica es una subfamilia:

$$\mathcal{C} \subseteq \mathcal{S}$$

tal que:

$$\bigcup_{S_v \in \mathcal{C}} S_v = \mathcal{U}.$$

En términos nodales, seleccionar $\mathcal{C}$ equivale a seleccionar un subconjunto de nodos $C \subseteq B$.

La versión de decisión pregunta si existe una cobertura con $|C| \leq k$. Esta forma corresponde al problema clásico NP-completo de cobertura de conjuntos. En la aplicación narrativa se usa una versión de optimización multiobjetivo: se busca un conjunto de nodos pequeño e importante, pero se penaliza el daño estructural producido si ese conjunto se retira de la red.

6.1. Variables de decisión

Para cada nodo candidato $v \in B$:

$$x_v = \begin{cases} 1, & \text{si el nodo } v \text{ es seleccionado,} \\ 0, & \text{en otro caso.} \end{cases}$$

Para cada arista objetivo $a \in A^*$:

$$r_a = \begin{cases} 1, & \text{si la arista } a \text{ se elimina al retirar } C, \\ 0, & \text{en otro caso.} \end{cases}$$

Definimos además la matriz de incidencia:

$$b_{av} = \begin{cases} 1, & \text{si } a \in S_v, \\ 0, & \text{en otro caso.} \end{cases}$$

6.2. Parámetros

- $n = |B|$: número de nodos candidatos.
- $m = |A^*|$: número de aristas objetivo.
- k : máximo de nodos seleccionables.
- $w_a > 0$: peso de la arista a .
- $\sigma_v > 0$: importancia del nodo v .
- $e_v \in \{0, 1\}$: elegibilidad del nodo; vale 0 si el usuario excluye el nodo, el medio, el término o el tipo de fuente.
- $q_{vh} \in \{0, 1\}$: pertenencia del nodo v al tipo h .

- L_h, U_h : mínimos y máximos opcionales por tipo de nodo.
- $\eta \in [0, 1]$: relevancia mínima ponderada opcional.

Sean:

$$W = \sum_{a \in A^*} w_a, \quad S = \sum_{v \in B} \sigma_v.$$

6.3. Restricciones

Las restricciones binarias son:

$$x_v \in \{0, 1\} \quad \forall v \in B, \quad r_a \in \{0, 1\} \quad \forall a \in A^*.$$

La remoción lógica de aristas se impone con:

$$\begin{aligned} r_a &\geq b_{av} x_v \quad \forall a \in A^*, \forall v \in B, \\ r_a &\leq \sum_{v \in B} b_{av} x_v \quad \forall a \in A^*. \end{aligned}$$

Así, una arista se cuenta como removida si toca al menos un nodo seleccionado:

$$A_R(C) = \{a = (i, j) \in A^* : i \in C \vee j \in C\}.$$

El presupuesto de complejidad interpretativa es:

$$\sum_{v \in B} x_v \leq k.$$

La exclusión manual y metodológica se modela como:

$$x_v \leq e_v \quad \forall v \in B.$$

Cuando se requiere controlar la composición del cubridor por tipo de nodo:

$$L_h \leq \sum_{v \in B} q_{vh} x_v \leq U_h \quad \forall h \in \mathcal{T}.$$

Por ejemplo, puede limitarse el número de documentos para evitar soluciones triviales y exigir presencia de actores, etapas o conceptos.

6.4. Objetivos

El modelo compara soluciones mediante tres objetivos normalizados:

$$\begin{aligned} f_1(x) &= \frac{\sum_{v \in B} x_v}{n} \quad \text{minimizar proporción de nodos seleccionados,} \\ f_2(x) &= \frac{\sum_{v \in B} \sigma_v x_v}{S} \quad \text{maximizar proporción de importancia nodal retenida,} \\ f_3(r) &= \frac{\sum_{a \in A^*} w_a r_a}{W} \quad \text{minimizar proporción de peso de aristas removidas.} \end{aligned}$$

El problema multiobjetivo queda:

$$\text{mín } f_1(x), \quad \text{máx } f_2(x), \quad \text{mín } f_3(r),$$

sujeto a las restricciones anteriores. Para trabajar en un espacio de maximización común se usa:

$$g(x, r) = (1 - f_1(x), f_2(x), 1 - f_3(r)) \in [0, 1]^3.$$

6.5. Dominancia de Pareto e hipervolumen

Una solución (x^1, r^1) domina a (x^2, r^2) si:

$$g_i(x^1, r^1) \geq g_i(x^2, r^2) \quad \forall i$$

y existe al menos un objetivo j tal que:

$$g_j(x^1, r^1) > g_j(x^2, r^2).$$

El frente de Pareto P contiene las soluciones factibles no dominadas.

Para comparar métodos se maximiza el hipervolumen:

$$HV(P) = \lambda_3 \left(\bigcup_{(x,r) \in P} [r_1, g_1(x, r)] \times [r_2, g_2(x, r)] \times [r_3, g_3(x, r)] \right),$$

donde $r = (0, 0, 0)$ es el punto de referencia y λ_3 es la medida de volumen en tres dimensiones. Un mayor hipervolumen indica un frente que combina mejor parsimonia, importancia nodal y bajo daño estructural por remoción de aristas.

6.6. Función escalar auxiliar

Los algoritmos heurísticos requieren ordenar candidatos durante la exploración. Para ello se usa una función auxiliar:

$$\Phi(x, r) = \alpha f_2(x) - \beta f_3(r) - \lambda f_1(x) - \sum_h \pi_h(x),$$

donde $\alpha, \beta, \lambda \geq 0$ y $\pi_h(x)$ penaliza violaciones o desbalances respecto a la composición deseada por tipo de nodo. Esta función no reemplaza el modelo multiobjetivo: sólo guía exploraciones auxiliares y barridos para generar soluciones candidatas cuyo desempeño final se evalúa por Pareto e hipervolumen.

7. Métodos de solución

El sistema implementa cuatro métodos locales. Para que la comparación sea válida, todos se ejecutan sobre la misma instancia (G, B, A^*, k) , con las mismas restricciones, el mismo criterio de factibilidad, el mismo presupuesto E de evaluaciones de función objetivo y las mismas métricas de calidad de frente. Sólo cambia la estrategia de búsqueda:

1. **Barrido glotón por suma ponderada:** recorre vectores de peso sobre u_1, u_2, u_3 y construye soluciones incrementales.
2. **MOEA:** mantiene una población de subconjuntos, cruza, muta y conserva un archivo de soluciones no dominadas.
3. **MOSA:** usa recocido simulado multiobjetivo; acepta soluciones por dominancia y temperatura cuando la comparación no es concluyente.
4. **MMC-MO:** adaptación discreta multiobjetivo del método de composición musical de Mora-Gutiérrez et al.; cada compositor conserva un arreglo de nodos y modifica su arreglo usando memoria guía LP-Pareto.

8. Adaptación del MMC

En el MMC original, una sociedad de compositores produce arreglos musicales. En este problema, cada arreglo es un subconjunto de nodos narrativos:

$$A_c = \{v_1, \dots, v_m\}, \quad m \leq k.$$

La calidad del arreglo se evalúa mediante el vector multiobjetivo y su aporte al frente de Pareto. El genio G^* es una solución guía seleccionada entre las mejores soluciones no dominadas. En cada iteración se aplican tres operadores:

- innovación guiada por genio: insertar nodos de G^* ;
- cambio: agregar, eliminar o sustituir nodos;
- intercambio social: recombinar el arreglo de un compositor con otro.

La solución nueva reemplaza a la anterior usando el mismo criterio común de dominancia con factibilidad: entre dos soluciones factibles se aplica Pareto; entre una factible y una infactible se conserva la factible; entre dos infactibles se prefiere la de menor violación total de restricciones. El desempeño global de todos los métodos se reporta con las mismas métricas:

- hipervolumen normalizado;
- número de puntos globalmente no dominados;
- distancia generacional inversa (IGD) contra el frente global combinado;
- spacing, como uniformidad de separación local entre puntos;
- dispersión o extensión del frente en el espacio (u_1, u_2, u_3) .

8.1. Relaxaciones PL y guía adaptativa del MMC-MO

Para evitar una inicialización arbitraria, antes de iniciar la sociedad de compositores se resuelven una sola vez, por instancia del problema, las relajaciones lineales monoobjetivo asociadas a:

$$u_1 = 1 - f_1, \quad u_2 = f_2, \quad u_3 = 1 - f_3,$$

y un punto balanceado. En la relajación se permite:

$$0 \leq x_v \leq 1, \quad 0 \leq r_a \leq 1.$$

Las soluciones fraccionales se redondean seleccionando los nodos de mayor valor x_v , respetando el presupuesto k . Estas soluciones no son el resultado final del MMC-MO; son una **guía inicial** o memoria de referencia:

$$M_0 = \{C_{u_1}^{LP}, C_{u_2}^{LP}, C_{u_3}^{LP}, C_{bal}^{LP}\}.$$

Durante la composición, el MMC-MO no vuelve a resolver los PL. La memoria guía se actualiza con soluciones no dominadas encontradas por los compositores:

$$M_{t+1} = \text{ND}(M_t \cup P_t),$$

donde P_t es el conjunto de soluciones evaluadas en la iteración t y ND conserva soluciones factibles no dominadas bajo el criterio de Pareto con manejo de infactibilidad. Esta estrategia hace que la guía inicial derivada de PL oriente la búsqueda, pero que el método conserve su carácter heurístico multiobjetivo.

9. Salidas

El sistema exporta:

- eventos narrativos por documento;
- nodos de la red narrativa;
- aristas ponderadas;
- solución del cubridor nodal;
- frente de Pareto;
- hipervolumen;
- superficie empírica $u_1 \times u_3 \rightarrow u_2$ para visualizar el frente tridimensional sin confundirlo con una proyección plana;
- métricas de cobertura, peso nodal, costo de aristas y valor objetivo de referencia.

10. Limitaciones metodológicas

El sistema depende de la calidad de los índices abiertos y de la posibilidad de descargar texto. Crossref, OpenAlex, Google News RSS, GDELT y Reddit no representan universos completos; representan mecanismos de muestreo auditables. La extracción completa se condiciona por permisos de fuente: antes de descargar HTML se consulta `robots.txt`; si la fuente es paywall, parcial o no permite descarga, el registro se conserva sólo como metadato o señal `ok_partial`. La limpieza automática reduce ruido, pero no sustituye la revisión manual de una muestra. Por ello, las conclusiones publicables deben reportar consulta, variantes, años, región, fuentes activas, exclusiones, tasa de errores de descarga, proporción de `ok/ok_partial` y criterios de validación humana.

11. Reproducibilidad

Todo el análisis corre localmente. Para ejecutar el solver:

```
python3 scripts/run_cover_solver.py \  
--input news_output \  
--method mmc \  
--max-nodes 12 \  
--edge-cost-weight 1.0
```