

Modelo multiobjetivo para cobertura de conceptos en redes narrativas

Documento técnico de trabajo

29 de julio de 2026

1 Propósito

Este documento formaliza el problema que resuelve el módulo de optimización de SIAN. El objetivo no es elegir “las palabras más frecuentes”, sino seleccionar un subconjunto pequeño de conceptos que cubra unidades narrativas relevantes, conserve alta relevancia semántica y mida el daño estructural que produciría retirar esos conceptos de la red.

2 Red narrativa

Sea $G = (V, E)$ una red narrativa. Cada nodo $i \in V$ puede representar un monograma, bigrama, trigrama, actor, fuente, marco o evento extraído del corpus. Cada arista $(i, j) \in E$ representa coaparición, relación semántica o relación estructural entre dos nodos.

Los pesos se normalizan en $[0, 1]$:

$$w_i = \frac{c_i}{\max_{k \in V} c_k}, \quad w_{ij} = \frac{c_{ij}}{\max_{(p,q) \in E} c_{pq}},$$

donde c_i es el conteo del nodo y c_{ij} el conteo o intensidad de la relación. Esta normalización evita mezclar escalas incompatibles entre frecuencia textual y peso de aristas.

3 Universo de cobertura

Sea $\mathcal{U}$ el universo de unidades narrativas que deben ser cubiertas. Una unidad puede ser:

- un documento;
- un marco narrativo;
- una comunidad semántica;
- un evento;
- una combinación fuente-año-tema.

Para cada unidad $u \in \mathcal{U}$ se define $S_u \subseteq V$, el conjunto de nodos que representan o explican esa unidad. Una solución selecciona nodos mediante variables binarias:

$$x_i = \begin{cases} 1, & \text{si el nodo } i \text{ es seleccionado,} \\ 0, & \text{en otro caso.} \end{cases}$$

La factibilidad se define por:

$$\sum_{i \in S_u} x_i \geq 1 \quad \forall u \in \mathcal{U}.$$

Esto es una variante del problema de cobertura de conjuntos. Es NP-completo en su versión de decisión, por lo que se justifica usar heurísticas y metaheurísticas cuando la red crece.

4 Aristas removidas

Para medir impacto estructural se define:

$$z_{ij} = \begin{cases} 1, & \text{si la arista } (i, j) \text{ se elimina al retirar el conjunto seleccionado,} \\ 0, & \text{en otro caso.} \end{cases}$$

La arista se elimina si al menos uno de sus extremos fue seleccionado y retirado. Por tanto:

$$z_{ij} \geq x_i, \quad z_{ij} \geq x_j, \quad z_{ij} \leq x_i + x_j.$$

Esto corrige una confusión importante: no se conserva una arista sólo porque ambos nodos estén seleccionados. El objetivo estructural cuenta las aristas que desaparecerían si se retirara el conjunto cubridor.

5 Objetivos normalizados

Se usan tres objetivos comparables:

$$\begin{aligned} u_1(x) &= 1 - \frac{\sum_{i \in V} x_i}{|V|}, \\ u_2(x) &= \frac{\sum_{i \in V} w_i x_i}{\sum_{i \in V} w_i}, \\ u_3(x) &= 1 - \frac{\sum_{(i,j) \in E} w_{ij} z_{ij}}{\sum_{(i,j) \in E} w_{ij}}. \end{aligned}$$

La interpretación es:

- u_1 : maximizar compacidad; usar pocos nodos.
- u_2 : maximizar relevancia; seleccionar nodos con alto peso narrativo.
- u_3 : maximizar preservación estructural; minimizar el peso de aristas removidas.

El problema multiobjetivo es:

$$\max F(x) = (u_1(x), u_2(x), u_3(x))$$

sujeto a las restricciones de cobertura y definición de z_{ij} .

6 Factibilidad

Las heurísticas deben usar el mismo criterio de factibilidad:

1. entre dos soluciones factibles, usar dominancia de Pareto;
2. entre una factible y una infactible, preferir la factible;
3. entre dos infactibles, preferir la de menor violación total:

$$\phi(x) = \sum_{u \in \mathcal{U}} \max \left(0, 1 - \sum_{i \in S_u} x_i \right).$$

Este criterio evita comparar soluciones inviables como si fueran resultados científicos.

7 Métodos comparables

Los métodos deben ejecutarse bajo el mismo número de evaluaciones de función objetivo y sobre el mismo grafo:

Método	Papel
Barrido glotón ponderado	Construye soluciones con distintos pesos sobre u_1, u_2, u_3 .
MOEA	Cruza y muta subconjuntos, conserva archivo no dominado.
MOSA	Usa recocido multiobjetivo con aceptación por dominancia, temperatura y factibilidad.
MMC-MO	Parte de soluciones guía obtenidas por relajaciones lineales y modifica arreglos de nodos mediante memoria adaptativa.

8 Relajaciones lineales

Antes de ejecutar heurísticas se resuelven relajaciones monoobjetivo para estimar puntos guía:

$$\max u_1(x), \quad \max u_2(x), \quad \max u_3(x),$$

con $x_i, z_{ij} \in [0, 1]$. Estas soluciones no sustituyen el problema entero, pero sirven para construir memoria inicial, estimar rangos y definir puntos de referencia para hipervolumen.

9 Evaluación estadística

El hipervolumen, la distancia generacional inversa y la dispersión deben calcularse sólo sobre el conjunto no dominado de cada método. Cada método debe ejecutarse al menos $k = 10$ veces. Se reportan:

- media, mediana, moda, mínimo, máximo y varianza;
- intervalo de confianza bootstrap al 95%;

- prueba de Wilcoxon pareada cuando se comparan métodos bajo las mismas semillas;
- frente no dominado en tres dimensiones y proyecciones bidimensionales auxiliares.

10 Alcance

El modelo no demuestra por sí mismo que un concepto sea culturalmente central. Produce candidatos estructuralmente relevantes que deben interpretarse con análisis humano, revisión de fuente y lectura contextual. Esa combinación es coherente con la metodología de análisis narrativo asistido por IA referida en Contactos [1].

References

- [1] Mora-Gutiérrez, R. A. y colaboradores. Artículo en *Contactos*. Disponible en: <https://contactos.izt.uam.mx/index.php/contactos/article/view/625>.

11 Actualización: evidencia disponible y requisitos de análisis (6 de octubre de 2026)

Esta actualización prevalece sobre supuestos anteriores de disponibilidad completa. Autoría, fecha y fuente se buscan, pero su recuperación no está garantizada. Cada campo conserva valor, evidencia, método y estado: explícito, inferido, buscado y no encontrado, no evaluable, no aplica o contradictorio. Se conservan candidatos contradictorios sin elegir arbitrariamente.

Publicación, actualización y consulta son fechas distintas. La precisión puede ser año, mes o día; no se completa información ausente. El año de búsqueda se conserva como `search_year`; `year` sólo refleja publicación explícita utilizable. Una fecha de detección de índice no es publicación. Un enlace PDF no acredita recuperación de texto completo.

Un documento sin autor o fecha puede aportar al análisis temático. Cada análisis presenta documentos utilizables, total, motivos de exclusión y cobertura por tipo de fuente. La cobertura no garantiza representatividad o suficiencia estadística. Los registros antiguos de fecha ambigua necesitan revisión humana para entrar en comparaciones temporales. El dominio de una URL no equivale a firma personal, editor identificado o ubicación del acontecimiento.

11.1 Representaciones matemáticas y revisión

La matriz documento–concepto usa 1 para presencia revisada, 0 sólo para ausencia tras revisión explícita del concepto y valor faltante para lo no evaluado. La proporción fuente–concepto usa como denominador los documentos efectivamente revisados para ese concepto. La red actor–concepto–postura conserva apoyo, rechazo y ambivalencia por separado; requiere cita literal y atribución revisada. Las relaciones dirigidas conservan tipo, documento y fragmento. Una causalidad atribuida por el texto no constituye un efecto causal demostrado. Los conteos temporales se calculan sobre la intersección revisada y fechada, con cobertura explícita. No equivalen a cambio en la opinión poblacional.

Los módulos heurísticos anteriores generan candidatos exploratorios. El módulo `evidence_model.py` verifica estados y citas, pero no sustituye juicio disciplinar. Las revisiones entran mediante JSON y

se conservan al exportar el corpus. No se infiere recepción a partir del mensaje original. Las observaciones pueden depender de una misma institución o acontecimiento; no se implementan pruebas inferenciales ni difusión con estos conteos.

11.2 Pseudocódigo de operación

1. Recuperar contenido y procedencia; buscar metadatos etiquetados cuando sea posible.
2. Conservar valor, evidencia y estado de cada campo; preservar conflictos y precisión.
3. Separar publicación, actualización, consulta y año de búsqueda.
4. Comprobar requisitos por análisis; registrar inclusión o motivo de exclusión.
5. Validar citas literales y atribuciones en las revisiones recibidas.
6. Construir matrices con valores faltantes distintos de cero; conservar signos de postura.
7. Exportar cobertura, matrices, relaciones y limitaciones del subconjunto utilizado.

La política completa, ejemplos y comandos reproducibles están en `EVIDENCIA_Y_MODELOS.md`. Los informes históricos no se convierten en nuevas mediciones por actualizar el software.

11.3 Contrato integral de corpus

La identidad y fusión se centralizan en `corpus_contract.py`, compartido por la interfaz y los comandos. Se conservan parámetros identificadores de URL, procedencias, variantes textuales y conflictos. La similitud de títulos no basta para fusionar trabajos distintos. Las señales de silencio indican no detección en fragmentos recuperados; no acreditan que una fuente ignore un tema. Las fechas anuales no permiten ordenar publicaciones dentro del año. El exportador relacional conserva tablas vacías cuando no existen interpretaciones revisadas. Véase `AUDITORIA_INTEGRAL_2026-10-06.md` para pruebas y límites del piloto.

11.4 Registros y etapas v2

Documento, versión y recuperación tienen identificadores separados. La selección requiere motivo, evidencia y revisor; los cambios invalidan interpretaciones previas. Se distinguen títulos, resúmenes y fragmentos. Descubrimiento, recuperación, extracción, selección, revisión y análisis tienen puntos de control para reanudación. El ejecutor de corpus guardados organiza la evidencia existente, sin simular nuevas descargas. Caché, reintentos limitados y registro transaccional complementan la escritura atómica. La especificación y pseudocódigo están en `ARQUITECTURA_REGISTROS_V2.md`.