

SIAN: evidencia disponible, datos faltantes y modelos descriptivos

Versión metodológica: 6 de octubre de 2026. Esta política sustituye cualquier instrucción anterior que permita confundir año de búsqueda con publicación, enlace PDF con texto completo, coocurrencia con relación validada o falta de datos con ausencia del fenómeno. Los informes históricos conservan su alcance.

Qué cambió

La recolección busca autoría y fechas en metadatos HTML etiquetados y JSON-LD. OpenAlex, Crossref y Redalyc conservan la autoría disponible en sus registros. La publicación, actualización y consulta son campos distintos. La búsqueda no garantiza recuperar ninguno de ellos. No se inventan autores ni fechas. Las firmas visibles sin metadatos etiquetados requieren revisión manual. La dirección institucional o el dominio no determinan autoría, territorio del acontecimiento ni identidad editorial.

El núcleo `evidence_model.py` se integra con la carga, enriquecimiento, persistencia de la araña, manifiesto y tablero Streamlit. El comando de auditoría migra los JSON existentes a una salida independiente. No modifica el corpus de entrada. `year` representa únicamente el año de publicación explícita utilizable; `search_year` conserva el valor heredado para rastrear el diseño de búsqueda. Los registros antiguos de procedencia temporal ambigua necesitan revisión.

Estados por campo

Estado de código	Significado	Uso
explicit	Encontrado explícitamente	Valor y evidencia disponibles; no garantiza veracidad de la afirmación
inferred	Inferido	Hipótesis identificada; fuera de análisis que exigen dato explícito
not_found	Buscado y no encontrado	Solo describe la búsqueda realizada
not_evaluable	No evaluable	Acceso, formato o procedencia insuficiente; incluye búsqueda no documentada en registros antiguos
not_applicable	No aplica	Decisión justificada según documento y pregunta
conflicting	Evidencias contradictorias	Se conservan candidatos; se necesita revisión

Cada celda contiene `value`, `state`, `evidence` y `method`. Las fechas conservan precisión de año, mes o día. No se completa día/mes. Los formatos no ISO deben normalizarse con evidencia o revisión; una fecha inválida queda fuera de la serie. El año encontrado en el cuerpo o en una URL no se convierte automáticamente en fecha de publicación. La fecha de detección de GDELT tampoco es publicación.

Requisitos por análisis

Análisis	Requisito	Alcance
Temático	Texto recuperado utilizable	Fragmentos incluidos, con cobertura parcial visible
Por fuente	Texto y fuente editorial identificada explícitamente	Diferencias entre documentos cubiertos
Temporal	Texto y publicación explícita de precisión suficiente	Subconjunto fechado; no representa automáticamente todo el corpus
Afirmaciones	Concepto, afirmación, cita literal y revisión validated	Interpretación humana documentada
Actor-concepto-postura	Afirmación revisada, emisor y respaldo textual de atribución	Posiciones expresadas; emisor no equivale al autor de la página
Narrativa	Descripción revisada y fragmento de respaldo	Lectura interpretativa documentada; el sistema no prueba por sí mismo que exista una narrativa
Recepción	Descripción revisada de recepción y evidencia recuperada	Debe revisarse sustantivamente que sean respuestas al mensaje, no solo contenido del mensaje

El tablero presenta utilizables/total, motivos de exclusión y distribución de cobertura por tipo de fuente. La cobertura mide disponibilidad, no representatividad o suficiencia estadística. Un documento sin autor o fecha sigue disponible para los análisis que no requieren esos campos.

Modelos matemáticos implementados

1. Matriz documento-concepto: 1 cuando existe una afirmación revisada del concepto; 0 solo cuando `reviewed_concepts` declara que se revisó ese concepto y no se registró presencia; null cuando no se sabe. Una coincidencia léxica nunca sustituye automáticamente este registro.
2. Fuente-concepto: proporción de documentos con el concepto sobre documentos efectivamente revisados para ese concepto y con fuente explícita. Se exportan numerador y denominador. Conceptos distintos pueden tener denominadores distintos.
3. Actor-concepto-postura: conteo de afirmaciones revisadas por actor, concepto y postura. Apoyo y rechazo permanecen separados; no se cancelan. La ambivalencia se conserva. La postura indeterminada no participa en esta red.
4. Relaciones dirigidas: `source`, `target` y `type` con documento y cita de respaldo. Son relaciones afirmadas o interpretadas en el texto; una causa atribuida no es un efecto causal estimado.
5. Conteos temporales: documentos con conceptos revisados y publicación explícita, agregados a la precisión solicitada. El resultado exporta la cobertura de la intersección revisado-fechado, además de la disponibilidad temporal general.

No se implementan inferencias poblacionales, pruebas de causalidad, difusión, alianzas o efectos psicológicos. Tampoco imputación de valores faltantes. Los resultados heurísticos anteriores continúan como candidatos exploratorios. Los documentos pueden depender de una misma institución o acontecimiento: los conteos no son observaciones independientes para pruebas inferenciales.

Algoritmos en pseudocódigo

```

PARA cada documento:
  conservar contenido original y procedencia
  buscar metadatos etiquetados cuando el acceso lo permita

```

PARA cada campo:

- conservar valor, evidencia, método y estado
- si hay conflicto: conservar candidatos sin elegir arbitrariamente
- separar publicación, actualización, consulta y año de búsqueda
- no usar año de búsqueda o detección del índice como publicación

PARA cada análisis:

- comprobar sus requisitos con evidencia disponible
- registrar inclusión o motivo de exclusión

mantener documento para otros análisis si faltan datos opcionales

PARA cada revisión:

- buscar document_id estable; rechazar ID desconocido o duplicado
- comprobar estado de metadatos y precisión de fechas
- comprobar cita literal en texto recuperado
- conservar interpretación revisada sin confundirla con verdad factual

PARA cada concepto y documento revisado:

- si hay evidencia validada: $X = 1$
- si la revisión declara cobertura de ese concepto y no presencia: $X = 0$
- de otro modo: $X = \text{null}$

AGRUPAR posiciones por actor, concepto y postura sin cancelar signos

CONTAR por fuente usando solo denominadores revisados

CONTAR por periodo usando intersección revisado y fechado

EXPORTAR matrices, relaciones, cobertura y limitaciones

Uso local y conservación de revisiones

```
python3 -m pip install -r requirements.txt
python3 -m streamlit run streamlit_app.py
python3 scripts/audit_evidence.py news_output --output audit_output --precision year
python3 scripts/audit_evidence.py news_output --output reviewed_output --reviews revisiones.json
python3 -m unittest discover -s tests -v
```

La interfaz permite descargar una plantilla, importar revisiones y descargar el corpus con evidencia y modelos. La revisión aplicada en la interfaz es temporal hasta descargar el corpus; no modifica silenciosamente el archivo de entrada. La CLI produce JSON/JSONL migrados, auditoría CSV, cobertura JSON y matrices CSV. Los IDs estables permiten conservar la revisión aunque se corrija la fecha.

Ejemplo de revisión, con texto sintético exclusivamente demostrativo:

```
[
  {
    "document_id": "copiar el identificador de review_template.json",
    "claims": [
      {
        "concept": "empleo",
        "statement": "La formación mejora el empleo",
        "speaker": "Ana",
        "speaker_evidence": "Ana",
        "stance": "support",
        "quote": "Ana sostiene que la formación mejora el empleo.",
        "review_status": "validated",
        "relations": [
          {
            "source": "formación",
            "target": "empleo",
            "type": "consecuencia_atribuida"
          }
        ]
      }
    ]
  }
],
```

```

    "reviewed_concepts": ["empleo"]
  }
]

```

La cita debe existir literalmente en el texto recuperado. El sistema verifica consistencia del registro, no reemplaza el juicio sociológico o psicológico. El código no estima confianza numérica ni convierte revisión humana en certeza.

Validación y límites pendientes

Las pruebas verifican fechas incompletas/contradictorias, bloqueos, migración sin mutación, IDs, citas inexistentes, denominadores, null frente a cero, conservación de apoyo/rechazo y rutas bibliográficas. Falta validar exhaustividad de extracción con un corpus externo y acuerdos entre codificadores. La limpieza heredada sigue siendo heurística: los textos deben revisarse antes de interpretar relaciones. Los modelos estadísticos multivariados, sensibilidad por institución/evento y contraste de codificadores requieren diseño y datos adicionales; no se presentan como implementados en esta actualización.

Contrato compartido de corpus y prueba integral

La revisión integral de octubre centraliza identidad y fusión en `corpus_contract.py`. Interfaz, ejecutor de planes, fusión por fuente y reconstrucción conservan evidencia y procedencia, sin fusionar documentos distintos por su título. Las URLs conservan parámetros identificadores. Un conflicto persiste; distintas fechas de consulta son historial de recuperación. El texto `recleaned` renueva su evidencia.

Las señales estructurales son candidatos. La no detección en fragmentos no significa que una fuente ignora un tema. Sin fecha no se establece orden temporal, y una fecha anual no permite ordenar publicaciones dentro de ese año. Pesos nulos permanecen nulos; el denominador de cálculo no altera el peso observado.

El exportador `scripts/export_corpus_database.py` entrega SQLite, Excel, CSV y JSON; las tablas de modelos sin revisión permanecen vacías. El caso de tatuaje produjo 891 registros exploratorios con contenido parcial y 15 referencias bibliográficas revisadas, sin atribuir posturas ni recepción. Véase `AUDITORIA_INTEGRAL_2026-10-06.md` para defectos, alcance de pruebas y límites de esta evaluación.

Arquitectura y registros v2 (6 de octubre de 2026)

El contrato versionado separa documento, versión y recuperación. Las etapas tienen puntos de control íntegros y reanudación; los lectores públicos usan caché y reintentos limitados. La selección revisada requiere motivo, evidencia y revisor, y los cambios invalidan revisiones dependientes. Las escrituras de corpus y manifiestos son atómicas y el registro SQLite es transaccional.

El ejecutor de corpus guardados organiza evidencia existente; no simula nuevas descargas ni revisión humana. Títulos, resúmenes y fragmentos se distinguen, y la cobertura de búsqueda requiere un denominador independiente. La especificación, pseudocódigo y comandos están en `ARQUITECTURA_REGISTROS_V2.md`.