

SIAN: metodología para construir y analizar corpus narrativos con datos públicos

Documento de trabajo para revisión editorial

29 de julio de 2026

Abstract

Este documento describe una metodología local para recolectar, limpiar, clasificar y analizar narrativas públicas a partir de noticias, artículos científicos abiertos, documentos institucionales, blogs, foros y otros textos web. El objetivo no es acumular grandes volúmenes de datos, sino construir un corpus trazable y balanceado que permita estudiar cómo cambia una narrativa entre fuentes, años y comunidades semánticas. La propuesta se apoya en redes complejas, procesamiento de lenguaje natural, análisis de sentimientos, extracción de marcos narrativos y un modelo multiobjetivo de cobertura de conceptos. Se toma como antecedente metodológico el trabajo publicado en Contactos sobre inteligencia artificial, narrativa mediática, redes y análisis semántico [1], así como el material suplementario local sobre interacción humano-computadora y generación recursiva de narrativas visuales [2].

1 Problema

Analizar una narrativa social no equivale a contar palabras. Una palabra frecuente puede ser ruido, una noticia breve puede condensar un cambio de encuadre y una conversación pública puede mostrar tensiones que no aparecen en los artículos científicos. Por eso el sistema SIAN se diseña como una plataforma de *datos inteligentes*: menos dependiente de fuerza bruta y más orientada a trazabilidad, balance de fuentes y estructura.

El caso de estudio inicial es el tatuaje como práctica cultural, estética, identitaria y sanitaria. Sin embargo, la arquitectura debe funcionar para otros tópicos. El tema puede cambiar; lo que permanece es el método: definir variantes, excluir falsos positivos, recolectar por capas, limpiar, consolidar y analizar redes narrativas.

2 Antecedente metodológico

El artículo de Contactos [1] es pertinente porque usa inteligencia artificial para estudiar narrativa mediática, evolución temporal, comunidades, sentimiento y estructuras semánticas. La lección central para este proyecto es que los textos no deben tratarse como registros aislados, sino como un sistema de relaciones entre fuentes, actores, temas y cambios de percepción.

El material suplementario proporcionado [2] añade una idea útil: la interpretación humana no desaparece. El proceso combina extracción computacional con revisión humana de significados, metáforas, actores y representaciones. En SIAN esta idea se traduce en una fase explícita de validación humana: el usuario puede excluir nodos, corregir grupos, revisar actores y decidir si un resultado tiene sentido cultural.

3 Arquitectura de recolección

La araña mezclada es la implementación de referencia. Esto significa que la búsqueda por fuente y la búsqueda completa usan el mismo plan; sólo cambia el alcance. Una corrida completa combina capas, años, rubros y variantes. Una corrida parcial ejecuta un subconjunto del mismo plan.

Capa	Fuentes	Papel narrativo
Noticias	GDELT, RSS, URLs semilla	Registran eventos, polémicas, casos y cambios de encuadre público.
Artículos científicos	OpenAlex, Crossref, Redalyc, PDF abierto	Aportan evidencia revisada o especializada; no sustituyen la conversación social.
Instituciones	Gobierno, reguladores, organismos	Muestran normas, alertas, políticas públicas y lenguaje oficial.
Foros y blogs	Foros abiertos, blogs, RSS públicos	Capturan experiencia, opinión y conversación orgánica cuando existe acceso público.
Otros documentos web	Páginas abiertas clasificables	Sirven como capa residual y deben mantenerse separados para no contaminar categorías.

4 Procesamiento

Cada candidato pasa por la misma secuencia lógica:

1. normalización de URL, DOI, medio, año y fuente;
2. descarga del texto cuando el acceso es público y legal;
3. limpieza de menús, anuncios, recomendaciones y restos de plantilla;
4. exclusión de dominios o términos que producen falsos positivos;
5. validación geográfica cuando el estudio lo requiere;
6. deduplicación por URL canónica, DOI o huella del título;
7. clasificación de fuente narrativa;
8. extracción de campos para análisis local;
9. guardado incremental en JSON;
10. consolidación final sin duplicados.

La limpieza debe ejecutarse antes de construir monogramas, bigramas, trigramas, actores o redes. Si se analiza texto sin normalizar, aparecen nodos irrelevantes como nombres de plantillas, marcas comerciales, menús, idiomas o restos de navegación.

5 Análisis narrativo

El análisis debe producir, al menos, cinco salidas:

1. distribución del corpus por año, fuente, medio, país y tipo narrativo;
2. términos, bigramas y trigramas filtrados por palabras vacías y exclusiones editables;
3. red semántica con nodos ponderados por frecuencia y aristas ponderadas por coaparición o relación;
4. comunidades mediante Louvain u otro método de partición;
5. comparación temporal de marcos: problema, actor, causa, solución y consecuencia.

La red no debe entenderse como una prueba automática de causalidad. Es un mapa exploratorio. Su valor está en hacer visibles agrupamientos, ausencias, repeticiones y desplazamientos de sentido.

6 Intervención humana

La intervención humana no es un adorno. Es parte del método. El usuario debe poder:

- excluir nodos irrelevantes;
- corregir actores;
- agrupar frases equivalentes;
- separar ruido comercial de uso cultural;
- revisar si una comunidad semántica tiene interpretación social;
- decidir si el corpus está balanceado antes de publicar resultados.

7 Límites

El sistema no garantiza que existan 50 noticias, 50 artículos o 50 comentarios por año. Lo que sí debe garantizar es que intenta buscarlos con una estrategia transparente, registra la cobertura obtenida y reporta brechas. Una brecha no es un error si la fuente no existe o no es legalmente accesible; sí es un error si el sistema deja de buscar sin reportarlo.

8 Conclusión

SIAN propone una metodología reproducible para pasar de textos dispersos a un corpus narrativo analizable. Su fortaleza no está en prometer automatización total, sino en combinar extracción local, trazabilidad, balance de fuentes, redes complejas y revisión humana. Para publicación, el punto crítico será demostrar que el corpus es suficiente y balanceado para la pregunta cultural planteada.

References

- [1] Mora-Gutiérrez, R. A. y colaboradores. Artículo en *Contactos*. Disponible en: <https://contactos.izt.uam.mx/index.php/contactos/article/view/625>.
- [2] Mora-Gutiérrez, R. A. y colaboradores. *Human-Computer Interaction for Recursive Prompt and Image Generation on Media Narratives of Violence in Mexico*. Material suplementario local proporcionado para el proyecto, 2026.