

SIAN: metodología para construir y analizar corpus narrativos con datos públicos

Documento de trabajo para revisión editorial

29 de julio de 2026

Abstract

Este documento describe una metodología local para recolectar, limpiar, clasificar y analizar narrativas públicas a partir de noticias, artículos científicos abiertos, documentos institucionales, blogs, foros y otros textos web. El objetivo no es acumular grandes volúmenes de datos, sino construir un corpus trazable y balanceado que permita estudiar cómo cambia una narrativa entre fuentes, años y comunidades semánticas. La propuesta se apoya en redes complejas, procesamiento de lenguaje natural, análisis de sentimientos, extracción de marcos narrativos y un modelo multiobjetivo de cobertura de conceptos. Se toma como antecedente metodológico el trabajo publicado en Contactos sobre inteligencia artificial, narrativa mediática, redes y análisis semántico [1], así como el material suplementario local sobre interacción humano-computadora y generación recursiva de narrativas visuales [2].

1 Problema

Analizar una narrativa social no equivale a contar palabras. Una palabra frecuente puede ser ruido, una noticia breve puede condensar un cambio de encuadre y una conversación pública puede mostrar tensiones que no aparecen en los artículos científicos. Por eso el sistema SIAN se diseña como una plataforma de *datos inteligentes*: menos dependiente de fuerza bruta y más orientada a trazabilidad, balance de fuentes y estructura.

El caso de estudio inicial es el tatuaje como práctica cultural, estética, identitaria y sanitaria. Sin embargo, la arquitectura debe funcionar para otros tópicos. El tema puede cambiar; lo que permanece es el método: definir variantes, excluir falsos positivos, recolectar por capas, limpiar, consolidar y analizar redes narrativas.

2 Antecedente metodológico

El artículo de Contactos [1] es pertinente porque usa inteligencia artificial para estudiar narrativa mediática, evolución temporal, comunidades, sentimiento y estructuras semánticas. La lección central para este proyecto es que los textos no deben tratarse como registros aislados, sino como un sistema de relaciones entre fuentes, actores, temas y cambios de percepción.

El material suplementario proporcionado [2] añade una idea útil: la interpretación humana no desaparece. El proceso combina extracción computacional con revisión humana de significados, metáforas, actores y representaciones. En SIAN esta idea se traduce en una fase explícita de validación humana: el usuario puede excluir nodos, corregir grupos, revisar actores y decidir si un resultado tiene sentido cultural.

3 Arquitectura de recolección

La araña mezclada es la implementación de referencia. Esto significa que la búsqueda por fuente y la búsqueda completa usan el mismo plan; sólo cambia el alcance. Una corrida completa combina capas, años, rubros y variantes. Una corrida parcial ejecuta un subconjunto del mismo plan.

Capa	Fuentes	Papel narrativo
Noticias	GDELT, RSS, URLs semilla	Registran eventos, polémicas, casos y cambios de encuadre público.
Artículos científicos	OpenAlex, Crossref, Redalyc, PDF abierto	Aportan evidencia revisada o especializada; no sustituyen la conversación social.
Instituciones	Gobierno, reguladores, organismos	Muestran normas, alertas, políticas públicas y lenguaje oficial.
Foros y blogs	Foros abiertos, blogs, RSS públicos	Capturan experiencia, opinión y conversación orgánica cuando existe acceso público.
Otros documentos web	Páginas abiertas clasificables	Sirven como capa residual y deben mantenerse separados para no contaminar categorías.

4 Procesamiento

Cada candidato pasa por la misma secuencia lógica:

1. normalización de URL, DOI, medio, año y fuente;
2. descarga del texto cuando el acceso es público y legal;
3. limpieza de menús, anuncios, recomendaciones y restos de plantilla;
4. exclusión de dominios o términos que producen falsos positivos;
5. validación geográfica cuando el estudio lo requiere;
6. deduplicación por URL canónica, DOI o huella del título;
7. clasificación de fuente narrativa;
8. extracción de campos para análisis local;
9. guardado incremental en JSON;
10. consolidación final sin duplicados.

La limpieza debe ejecutarse antes de construir monogramas, bigramas, trigramas, actores o redes. Si se analiza texto sin normalizar, aparecen nodos irrelevantes como nombres de plantillas, marcas comerciales, menús, idiomas o restos de navegación.

5 Análisis narrativo

El análisis debe producir, al menos, cinco salidas:

1. distribución del corpus por año, fuente, medio, país y tipo narrativo;
2. términos, bigramas y trigramas filtrados por palabras vacías y exclusiones editables;
3. red semántica con nodos ponderados por frecuencia y aristas ponderadas por coaparición o relación;
4. comunidades mediante Louvain u otro método de partición;
5. comparación temporal de marcos: problema, actor, causa, solución y consecuencia.

La red no debe entenderse como una prueba automática de causalidad. Es un mapa exploratorio. Su valor está en hacer visibles agrupamientos, ausencias, repeticiones y desplazamientos de sentido.

6 Intervención humana

La intervención humana no es un adorno. Es parte del método. El usuario debe poder:

- excluir nodos irrelevantes;
- corregir actores;
- agrupar frases equivalentes;
- separar ruido comercial de uso cultural;
- revisar si una comunidad semántica tiene interpretación social;
- decidir si el corpus está balanceado antes de publicar resultados.

7 Límites

El sistema no garantiza que existan 50 noticias, 50 artículos o 50 comentarios por año. Lo que sí debe garantizar es que intenta buscarlos con una estrategia transparente, registra la cobertura obtenida y reporta brechas. Una brecha no es un error si la fuente no existe o no es legalmente accesible; sí es un error si el sistema deja de buscar sin reportarlo.

8 Conclusión

SIAN propone una metodología reproducible para pasar de textos dispersos a un corpus narrativo analizable. Su fortaleza no está en prometer automatización total, sino en combinar extracción local, trazabilidad, balance de fuentes, redes complejas y revisión humana. Para publicación, el punto crítico será demostrar que el corpus es suficiente y balanceado para la pregunta cultural planteada.

References

- [1] Mora-Gutiérrez, R. A. y colaboradores. Artículo en *Contactos*. Disponible en: <https://contactos.izt.uam.mx/index.php/contactos/article/view/625>.
- [2] Mora-Gutiérrez, R. A. y colaboradores. *Human-Computer Interaction for Recursive Prompt and Image Generation on Media Narratives of Violence in Mexico*. Material suplementario local proporcionado para el proyecto, 2026.

9 Actualización: evidencia disponible y requisitos de análisis (6 de octubre de 2026)

Esta actualización prevalece sobre supuestos anteriores de disponibilidad completa. Autoría, fecha y fuente se buscan, pero su recuperación no está garantizada. Cada campo conserva valor, evidencia, método y estado: explícito, inferido, buscado y no encontrado, no evaluable, no aplica o contradictorio. Se conservan candidatos contradictorios sin elegir arbitrariamente.

Publicación, actualización y consulta son fechas distintas. La precisión puede ser año, mes o día; no se completa información ausente. El año de búsqueda se conserva como `search_year`; `year` sólo refleja publicación explícita utilizable. Una fecha de detección de índice no es publicación. Un enlace PDF no acredita recuperación de texto completo.

Un documento sin autor o fecha puede aportar al análisis temático. Cada análisis presenta documentos utilizables, total, motivos de exclusión y cobertura por tipo de fuente. La cobertura no garantiza representatividad o suficiencia estadística. Los registros antiguos de fecha ambigua necesitan revisión humana para entrar en comparaciones temporales. El dominio de una URL no equivale a firma personal, editor identificado o ubicación del acontecimiento.

9.1 Representaciones matemáticas y revisión

La matriz documento–concepto usa 1 para presencia revisada, 0 sólo para ausencia tras revisión explícita del concepto y valor faltante para lo no evaluado. La proporción fuente–concepto usa como denominador los documentos efectivamente revisados para ese concepto. La red actor–concepto–postura conserva apoyo, rechazo y ambivalencia por separado; requiere cita literal y atribución revisada. Las relaciones dirigidas conservan tipo, documento y fragmento. Una causalidad atribuida por el texto no constituye un efecto causal demostrado. Los conteos temporales se calculan sobre la intersección revisada y fechada, con cobertura explícita. No equivalen a cambio en la opinión poblacional.

Los módulos heurísticos anteriores generan candidatos exploratorios. El módulo `evidence_model.py` verifica estados y citas, pero no sustituye juicio disciplinar. Las revisiones entran mediante JSON y se conservan al exportar el corpus. No se infiere recepción a partir del mensaje original. Las observaciones pueden depender de una misma institución o acontecimiento; no se implementan pruebas inferenciales ni difusión con estos conteos.

9.2 Pseudocódigo de operación

1. Recuperar contenido y procedencia; buscar metadatos etiquetados cuando sea posible.
2. Conservar valor, evidencia y estado de cada campo; preservar conflictos y precisión.
3. Separar publicación, actualización, consulta y año de búsqueda.

4. Comprobar requisitos por análisis; registrar inclusión o motivo de exclusión.
5. Validar citas literales y atribuciones en las revisiones recibidas.
6. Construir matrices con valores faltantes distintos de cero; conservar signos de postura.
7. Exportar cobertura, matrices, relaciones y limitaciones del subconjunto utilizado.

La política completa, ejemplos y comandos reproducibles están en `EVIDENCIA_Y_MODELOS.md`. Los informes históricos no se convierten en nuevas mediciones por actualizar el software.

9.3 Contrato integral de corpus

La identidad y fusión se centralizan en `corpus_contract.py`, compartido por la interfaz y los comandos. Se conservan parámetros identificadores de URL, procedencias, variantes textuales y conflictos. La similitud de títulos no basta para fusionar trabajos distintos. Las señales de silencio indican no detección en fragmentos recuperados; no acreditan que una fuente ignore un tema. Las fechas anuales no permiten ordenar publicaciones dentro del año. El exportador relacional conserva tablas vacías cuando no existen interpretaciones revisadas. Véase `AUDITORIA_INTEGRAL_2026-10-06.md` para pruebas y límites del piloto.

9.4 Registros y etapas v2

Documento, versión y recuperación tienen identificadores separados. La selección requiere motivo, evidencia y revisor; los cambios invalidan interpretaciones previas. Se distinguen títulos, resúmenes y fragmentos. Descubrimiento, recuperación, extracción, selección, revisión y análisis tienen puntos de control para reanudación. El ejecutor de corpus guardados organiza la evidencia existente, sin simular nuevas descargas. Caché, reintentos limitados y registro transaccional complementan la escritura atómica. La especificación y pseudocódigo están en `ARQUITECTURA_REGISTROS_V2.md`.